DOSSIER PROJET CDA

HelpMeDraft

Assistant de rédaction professionnelle assistée par IA, à inférence locale

Ophélie Bellissens · Metz Numeric School · Octobre 2026

Commanditaire : LexiCorp (contexte de formation)

Déroulé

Six temps, quarante minutes. Les numéros renvoient aux sections du dossier.

1	**Le contexte et le besoin**	Dossier § 2 et § 3	≈ 4 min
2	**La gestion de projet**	§ 4	≈ 5 min
3	**La conception**	§ 5	≈ 12 min
4	**La réalisation**	§ 6 et § 7	≈ 7 min
5	**La sécurité**	§ 8	≈ 5 min
6	**Tests, veille et bilan**	§ 9, § 10, § 11	≈ 8 min

1

Le contexte et le besoin

Dossier § 2 — le cahier des charges · § 3 — l'entreprise et le service

Aider à écrire, pas seulement à classer

LexiCorp, éditeur d'outils de gestion documentaire pour les PME, ouvre un nouveau service.

1 Le constat

Dans une PME, les écrits courants — courriels, notes, comptes rendus — mobilisent des collaborateurs qui ne sont pas rédacteurs. Qualité inégale, reprises multiples.

2 La demande

Une application web qui assiste la rédaction à l'aide d'une IA générative, dans un espace personnel sécurisé.

3 Mon rôle

Conceptrice développeuse full-stack, seule sur la chaîne : analyse, conception, front, back, base de données, sécurisation, documentation.

Les quatre objectifs du cahier des charges

Rédiger et stocker

ses documents professionnels

Suggérer et reformuler

via un modèle de langage

Un espace sécurisé

authentification et historique

Se conformer

RGPD, ANSSI, RGAA

Périmètre et exigences

Cinq blocs fonctionnels, quatre domaines d'exigences, et des limites assumées.

A–E

Périmètre fonctionnel

Gestion utilisateur — inscription, connexion, mot de passe oublié, deux rôles
Éditeur Markdown et trois commandes IA : reformuler, corriger, compléter
Gestion documentaire — CRUD, dossiers, enregistrement automatique, historique IA
Intégration IA — appels serveur, prompt engineering, affichage différencié
Back-office — comptes, statistiques, quota de 20 requêtes / 24 h

NF

Exigences non fonctionnelles

Sécurité — hachage, JWT, protection XSS / CSRF / injections
Accessibilité — RGAA 4.1.2, contrastes, clavier, ARIA
RGPD — consentement explicite, aucune donnée transmise à un tiers
Éco-conception — chargement différé, dépendances limitées, compression
AI Act — transparence, applicable depuis le 2 août 2026 (hors cahier des charges)

Hors périmètre, assumé : facturation et abonnements · collaboratif temps réel · application mobile native · export bureautique propriétaire · hébergement cloud de production.

2

La gestion de projet

Dossier § 4 — méthode, planning, versions, arbitrages

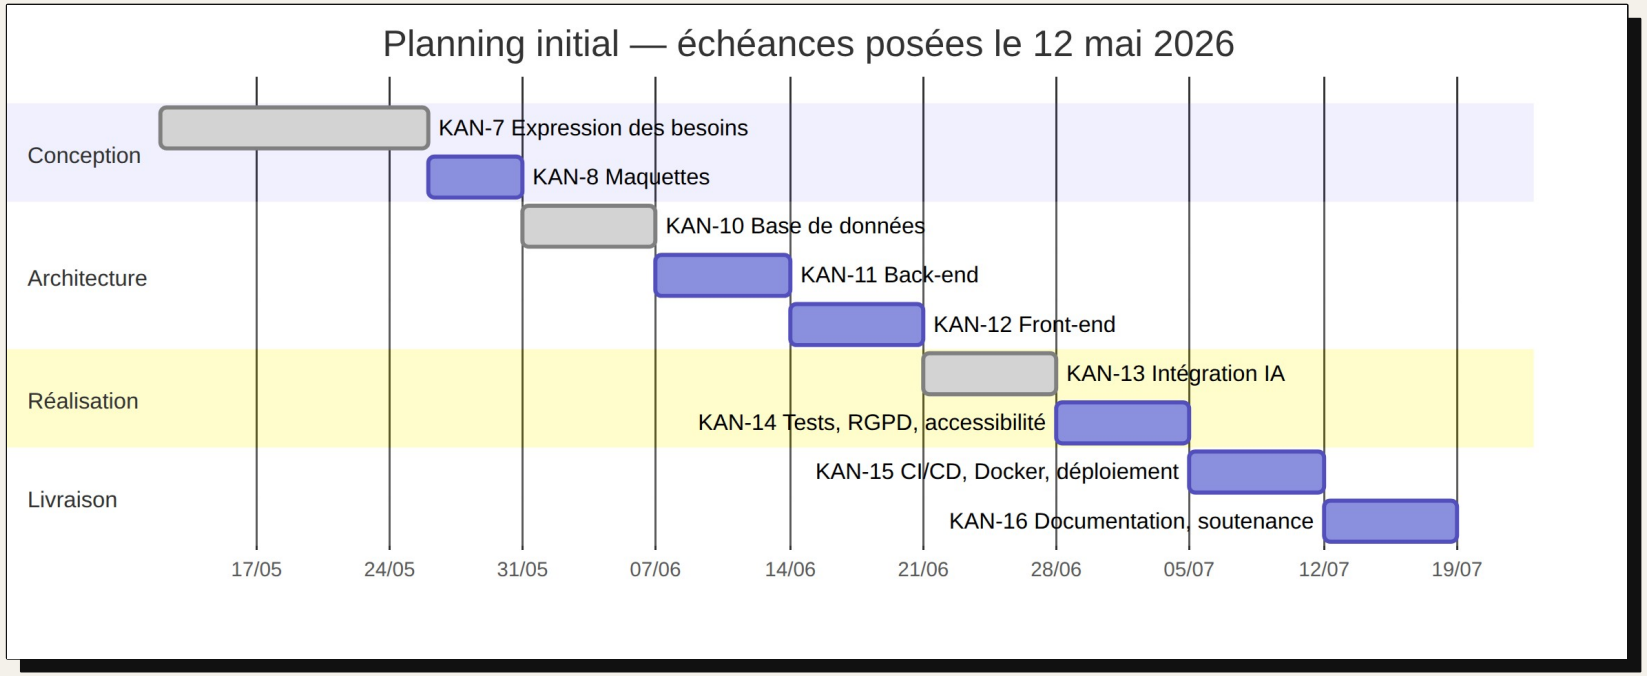
Des lots verticaux, pas des couches horizontales

1 semaine
durée d'une itération

6 / 6
étapes du plan engagées

13
lots fonctionnels terminés

3
points restants, documentés



Planning initial repris du cahier des charges et découpé en lots verticaux.

Trois arbitrages, et une erreur corrigée

Les décisions que je défends, et celle que j'ai dû reprendre.

1 Session révocable

Un JWT seul ne se révoque pas. Table user_session + rotation des refresh tokens : rejouer un jeton consommé est traité comme un vol.

2 Quota par agrégation

Comptage sur le journal des appels, pas un compteur sur l'utilisateur : la valeur ne peut pas se désynchroniser et l'historique reste auditable.

3 Confidentialité

Inférence locale : les contenus ne quittent pas l'infrastructure. Contreparties assumées — latence, qualité, maintenance.

! L'erreur : une dérive du positionnement éditorial

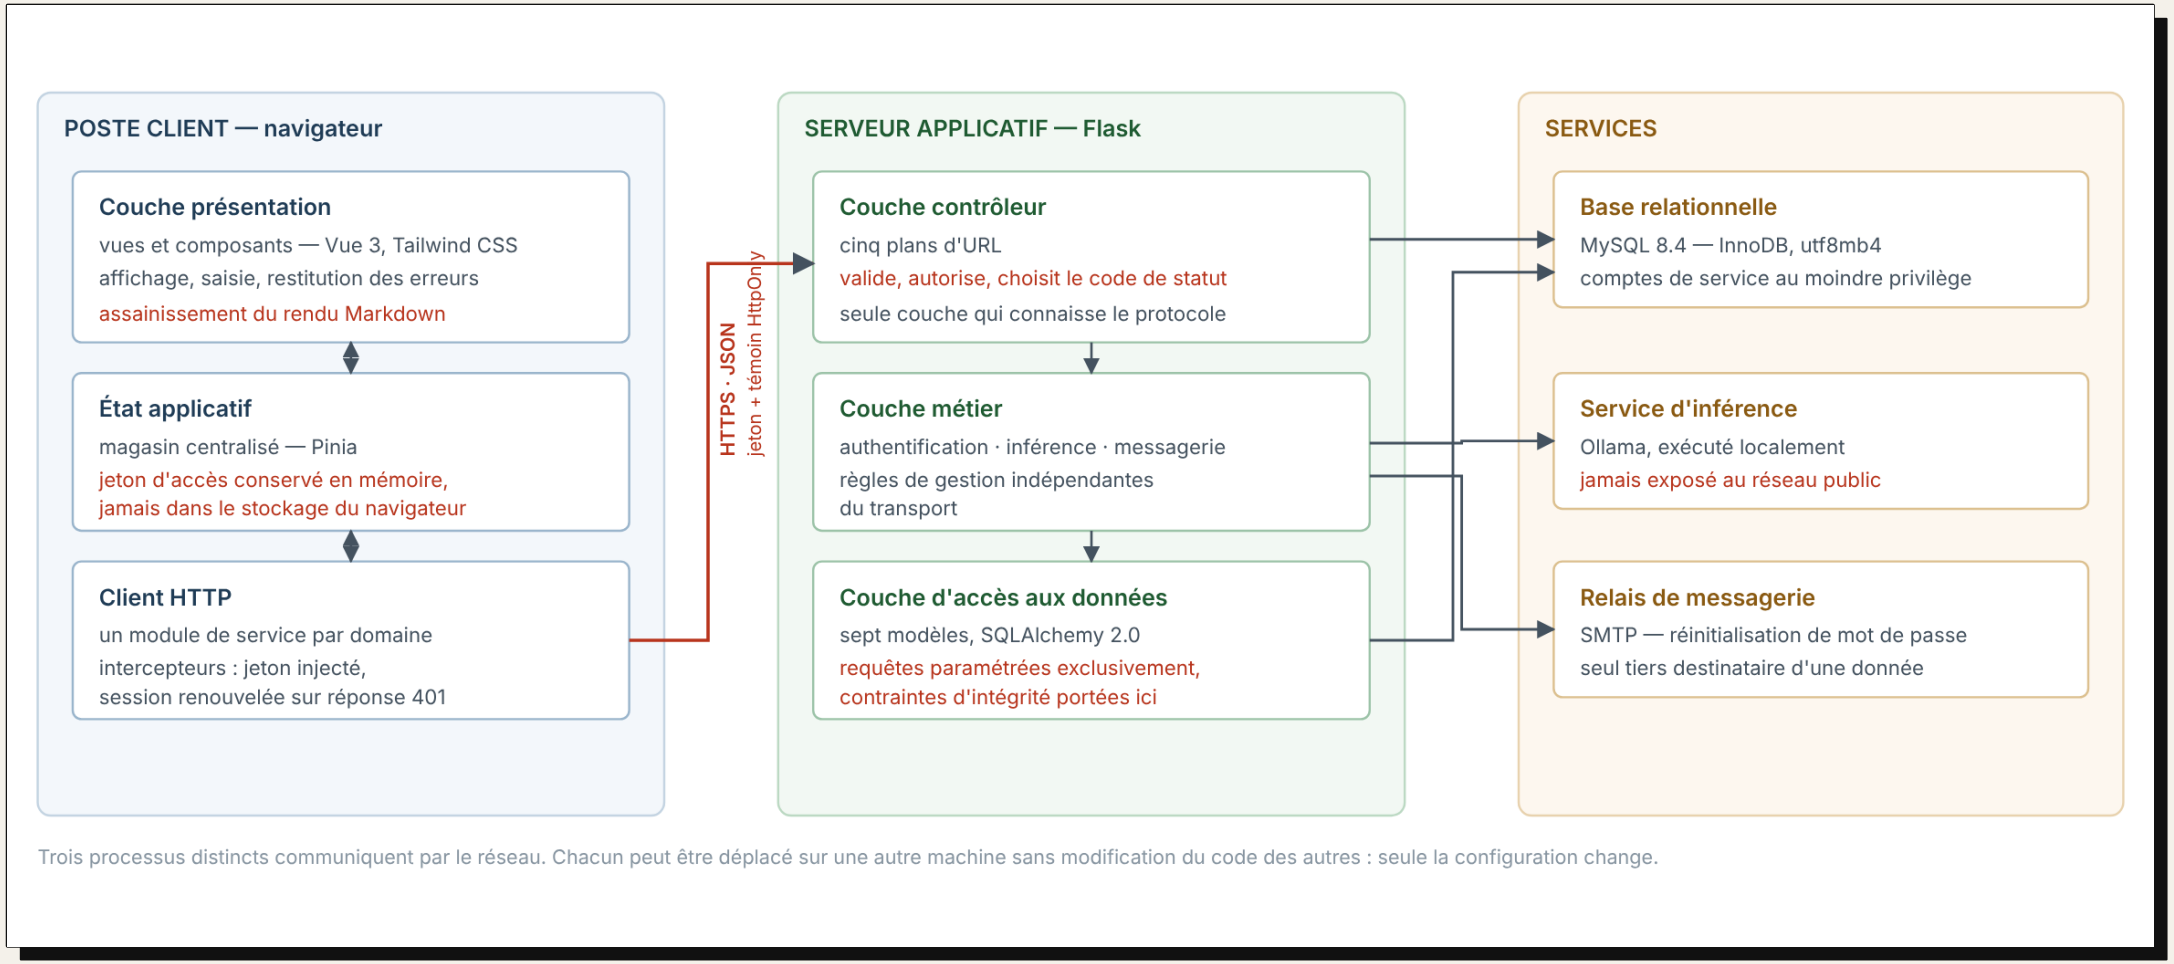
Vingt libellés avaient glissé vers un positionnement « juridique » absent du cahier des charges. Le dernier résidu n'était pas visible : les gabarits de prompt du backend. Invisibles, mais envoyés au modèle à chaque appel — donc avec un effet réel. Un prompt est du code : il se teste comme du code (cas TU-04).

3

La conception

Dossier § 5 — architecture, maquettes, modèle de données, cas d'utilisation

Le navigateur ne parle jamais au moteur d'inférence



Trois processus distincts communiquent par le réseau. Chacun peut être déplacé sur une autre machine sans modification du code des autres : seule la configuration change.

Architecture logicielle — trois niveaux et services périphériques (dossier § 5.2).

Aucun import Flask dans services/

La règle d'architecture qui rend le plan de tests possible.

Couche	Responsabilité	Ne contient jamais
Présentation `app/routes/`	Validation des entrées, codes de retour, sérialisation JSON	Règle métier
Métier `app/services/`	Hachage, cycle de vie des jetons, prompts, appel au modèle, courriels	Flask : request, response
Persistance `database/db.py`	Modèles SQLAlchemy, relations, contraintes, requêtes et agrégations	Logique de présentation

Côté front, la même règle : aucune vue n'appelle axios. L'intercepteur qui rejoue une requête après un 401 est donc écrit une seule fois.

Neuf planches, une intention par écran

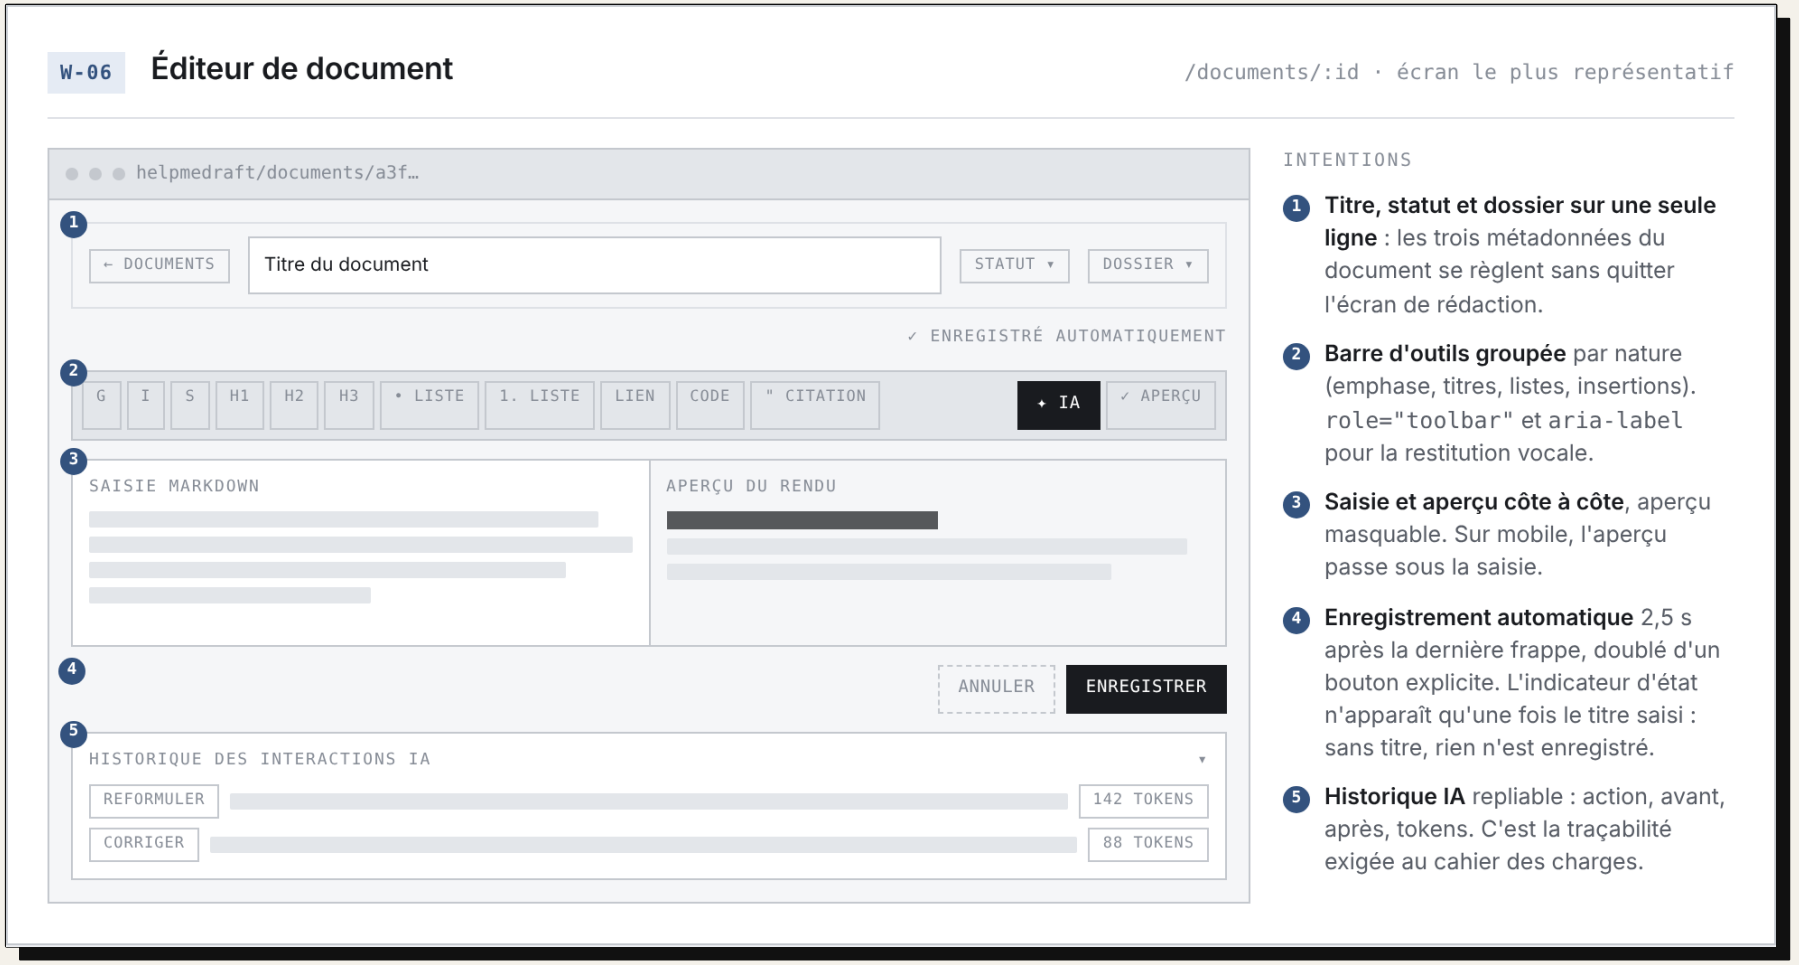
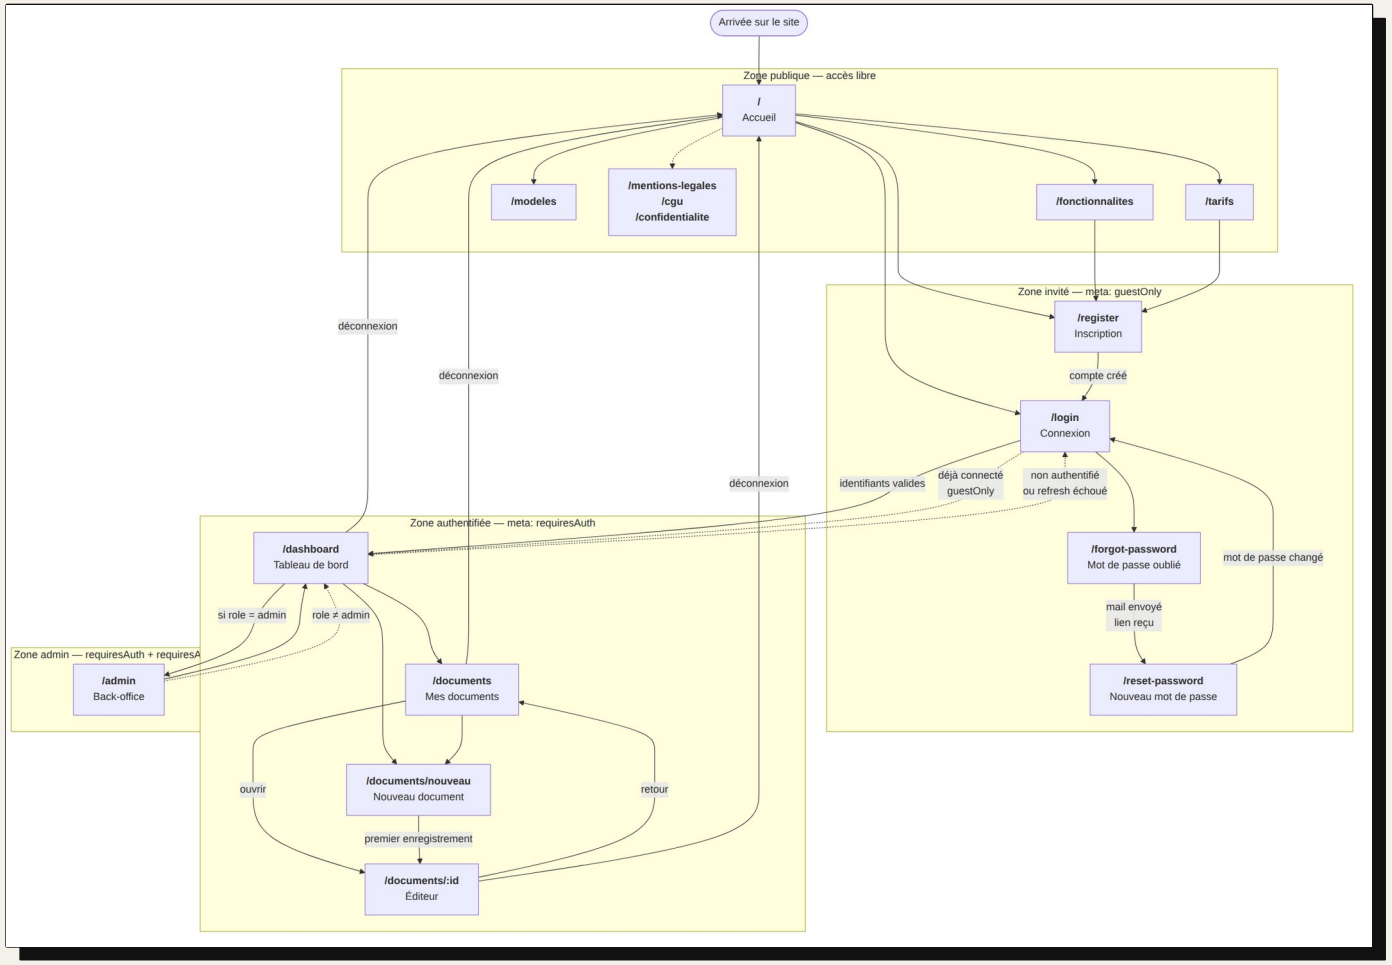


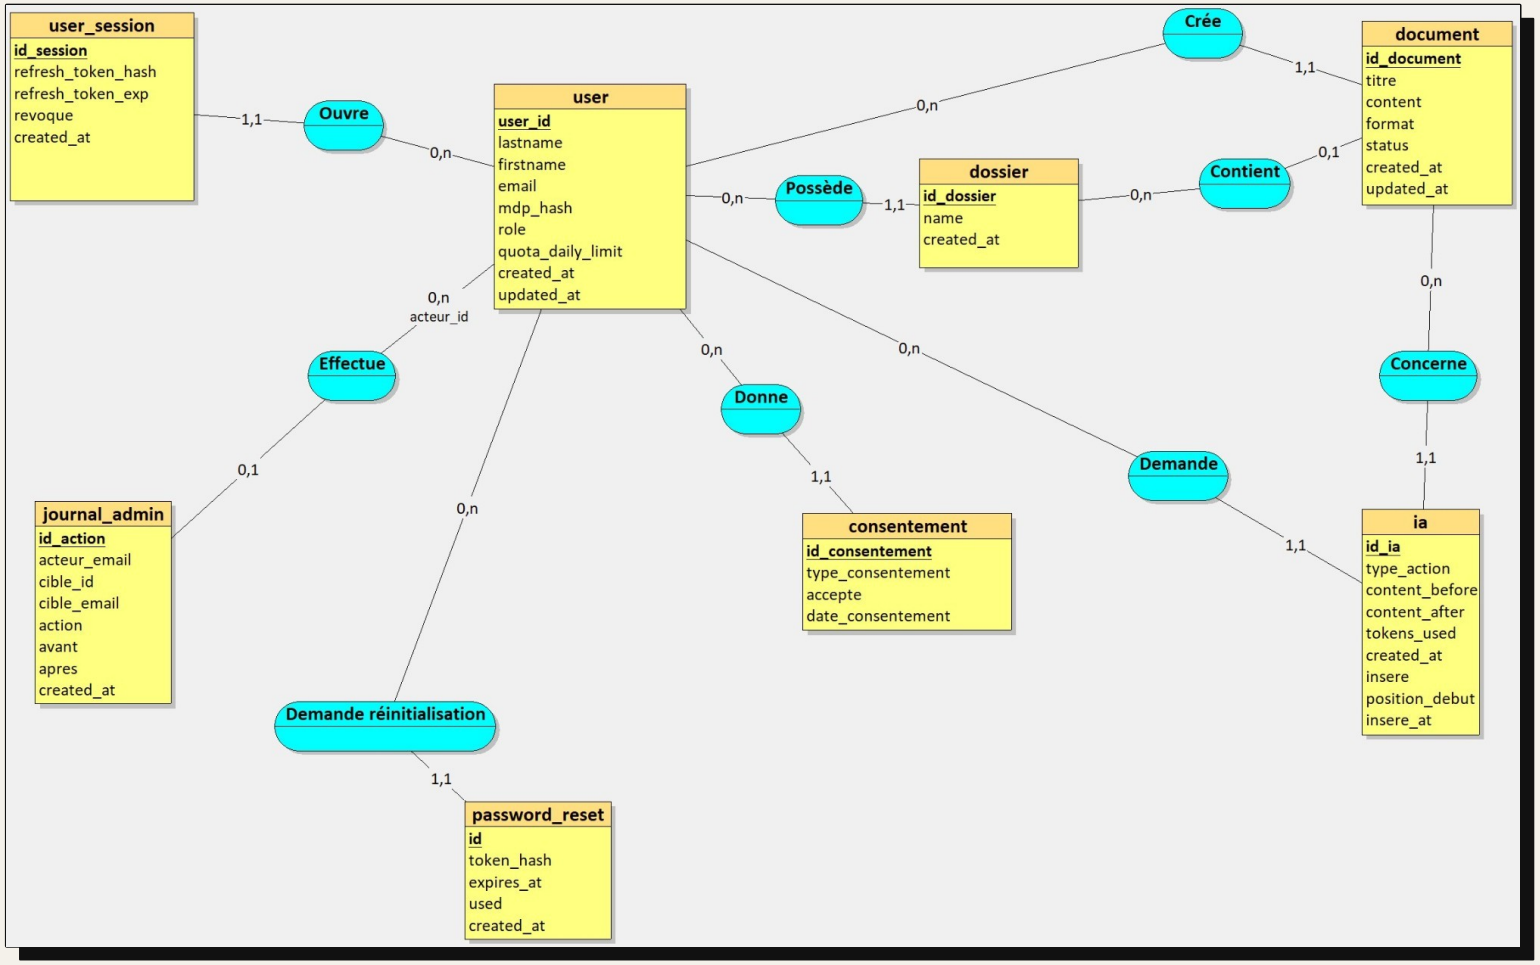
Planche W-06 — éditeur de document, l'écran le plus représentatif (dossier § 5.3, § 12.1).

Trois zones, trois gardes de routeur



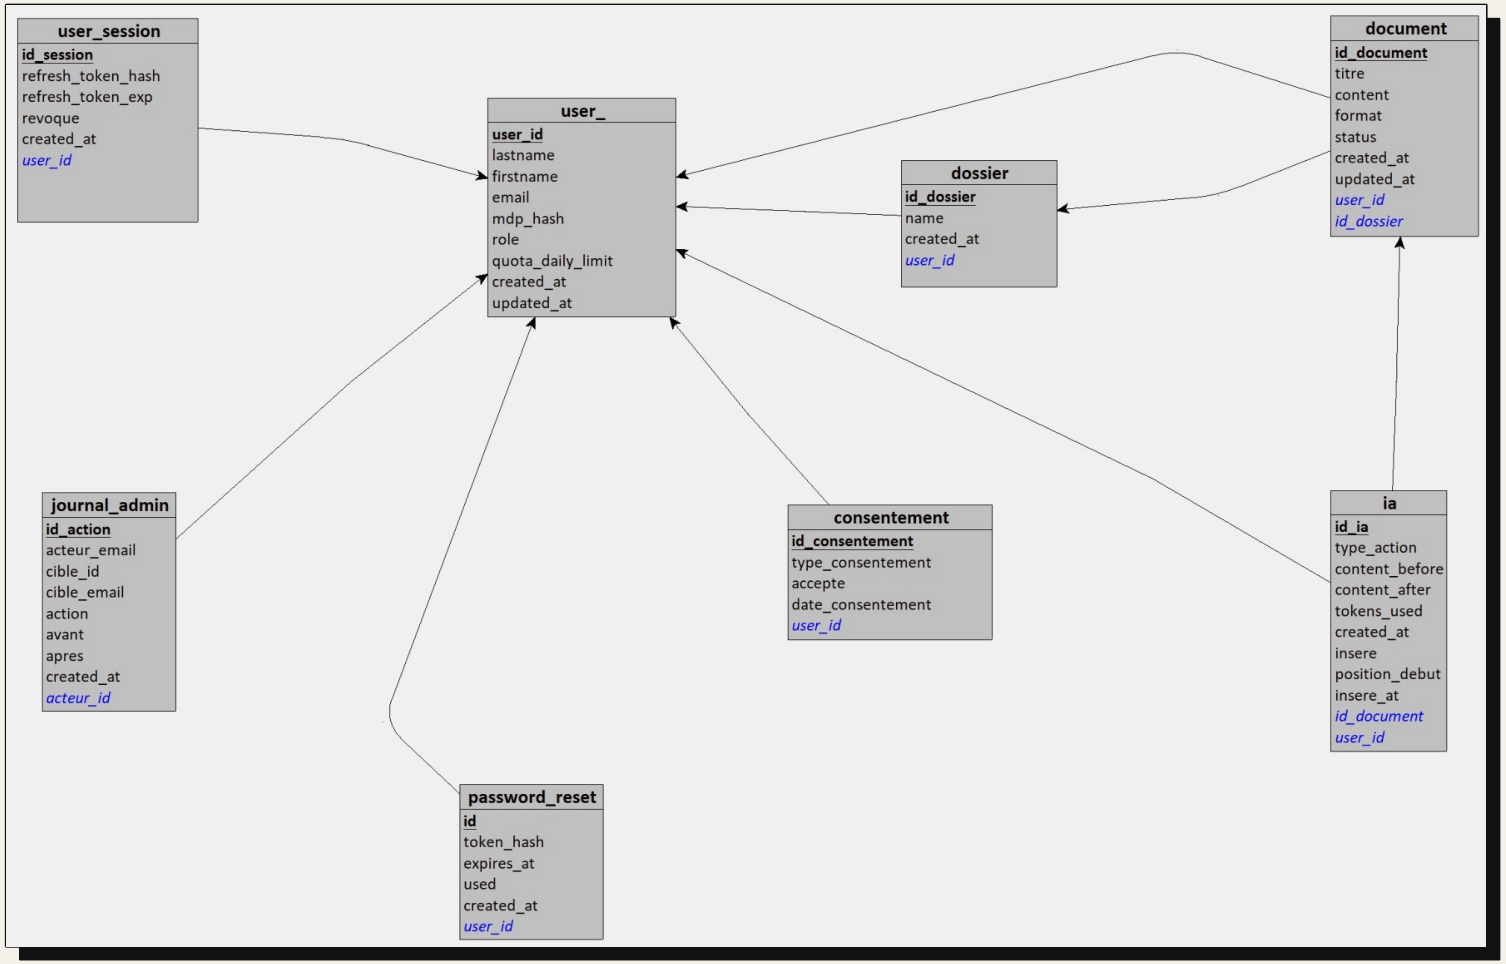
Enchaînement des écrans et gardes du routeur (dossier § 5.3).

Huit entités, des UUID, des cascades côté SGBD



Modèle conceptuel de données (dossier § 5.4).

Les associations deviennent des clés étrangères



Modèle logique de données (dossier § 5.4) ; modèle physique et script MySQL en § 5.4 et § 5.5.

Trois acteurs, un périmètre cloisonné

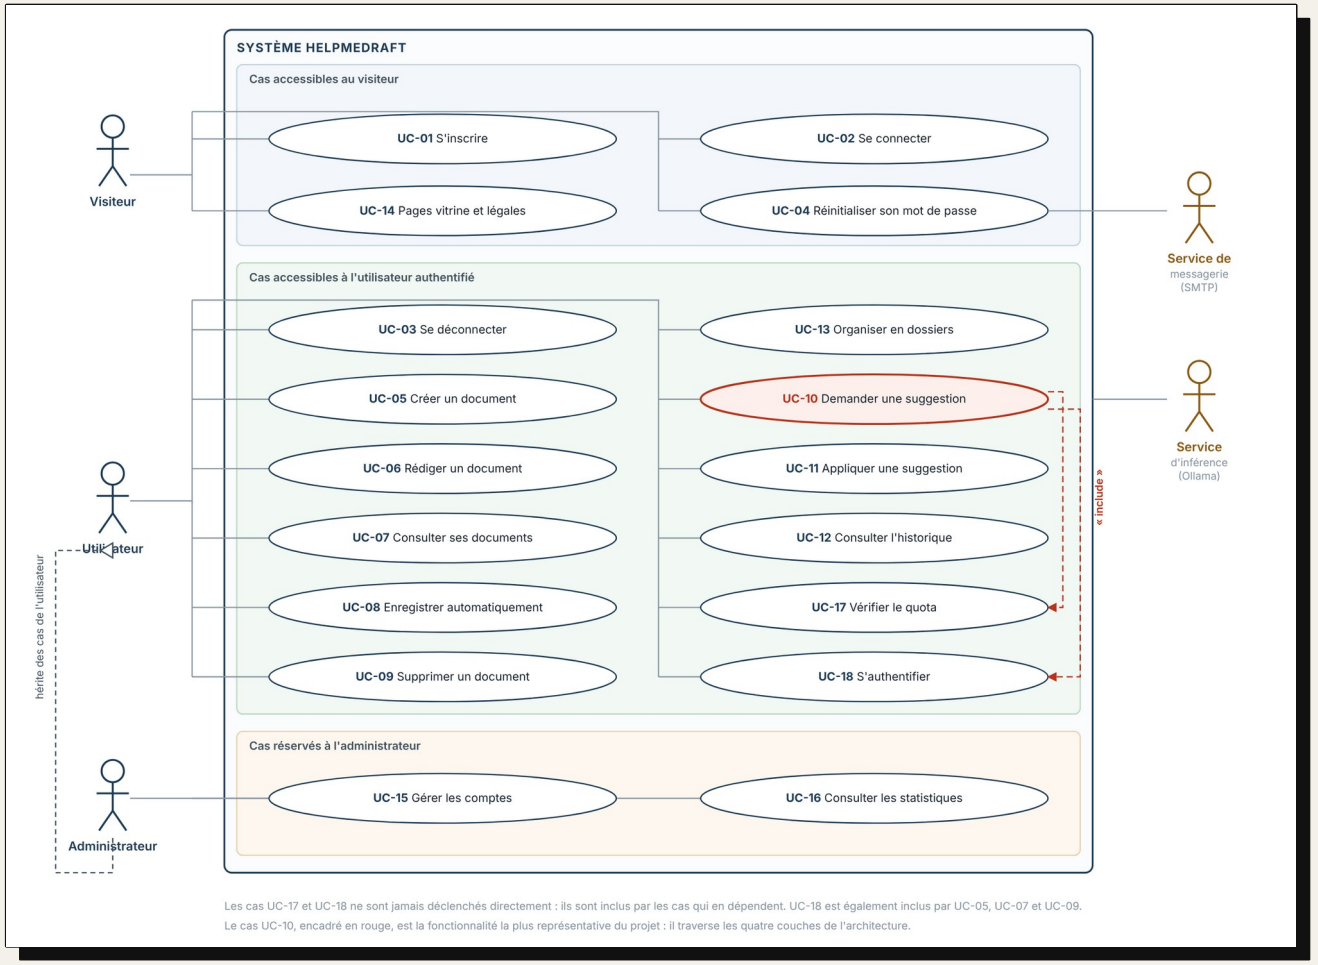
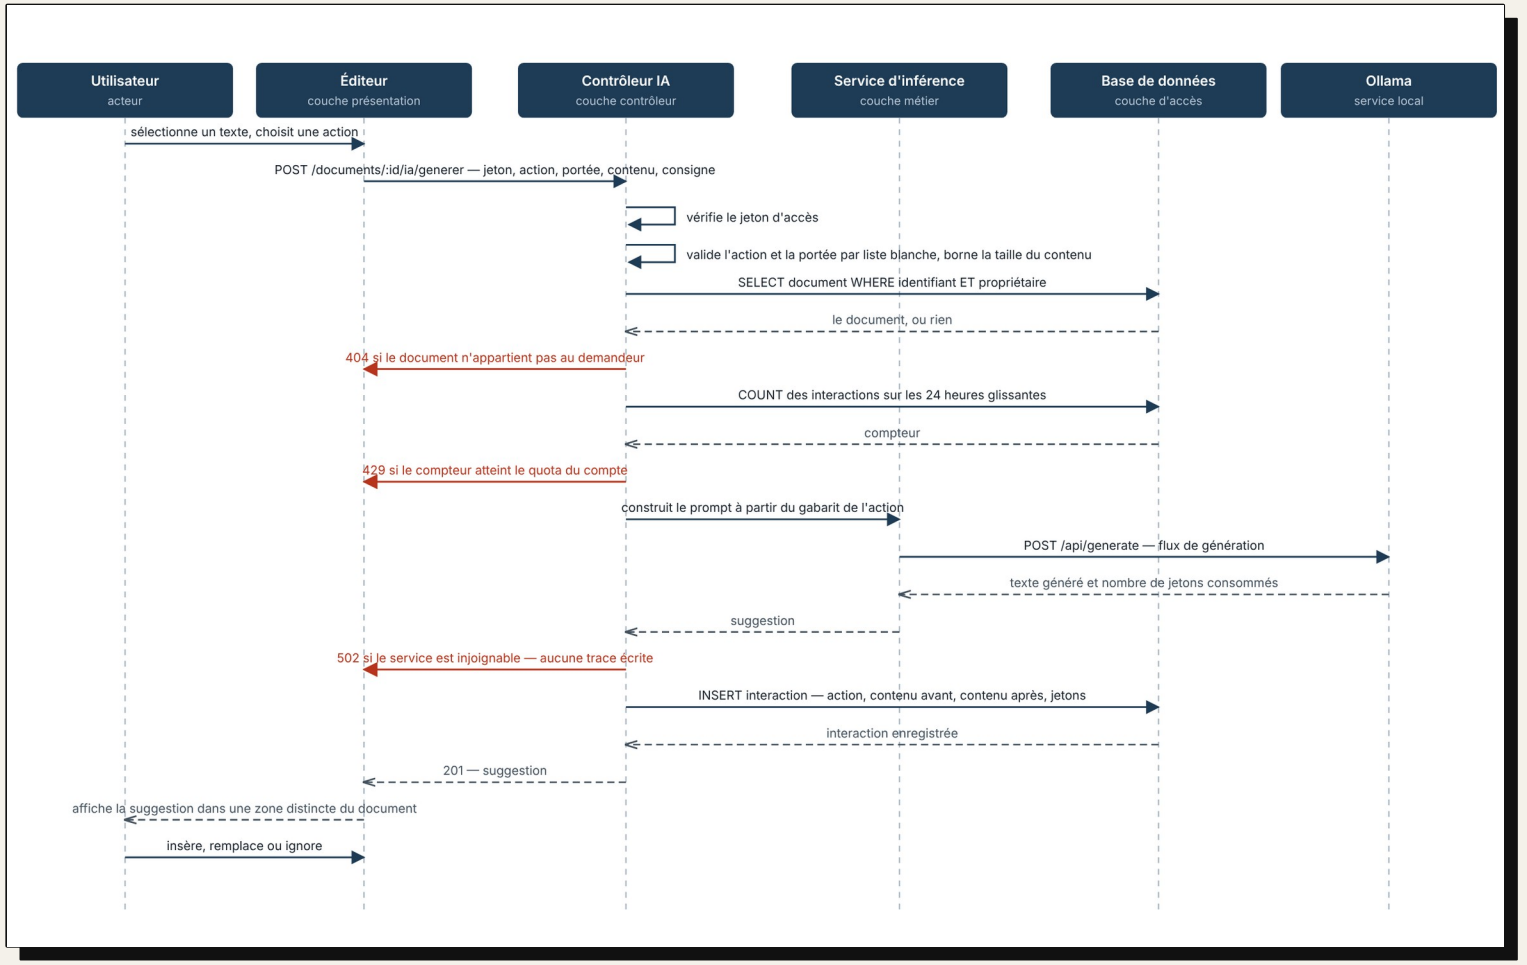


Diagramme des cas d'utilisation (dossier § 5.6).

Cinq contrôles avant le moindre appel au modèle



Séquence — génération d'une assistance IA (dossier § 5.7).

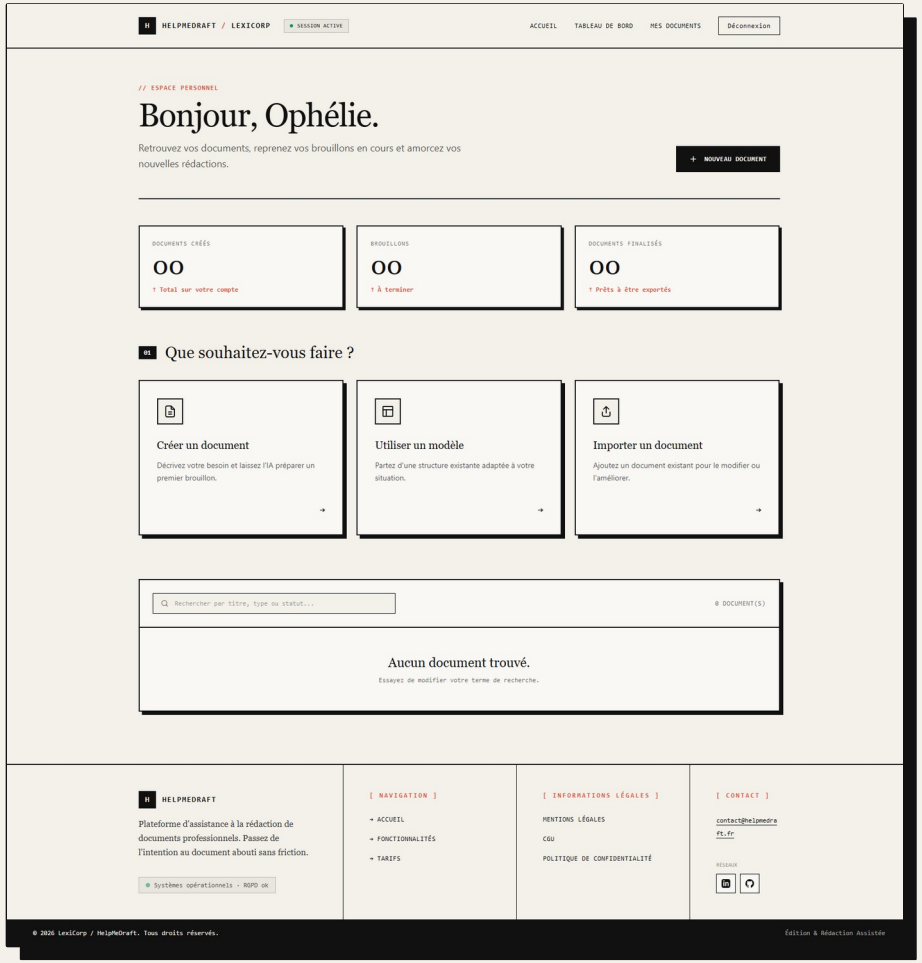
4

La réalisation

Dossier § 6 — spécifications techniques · § 7 — écrans et extraits de code

Supprimer la page blanche

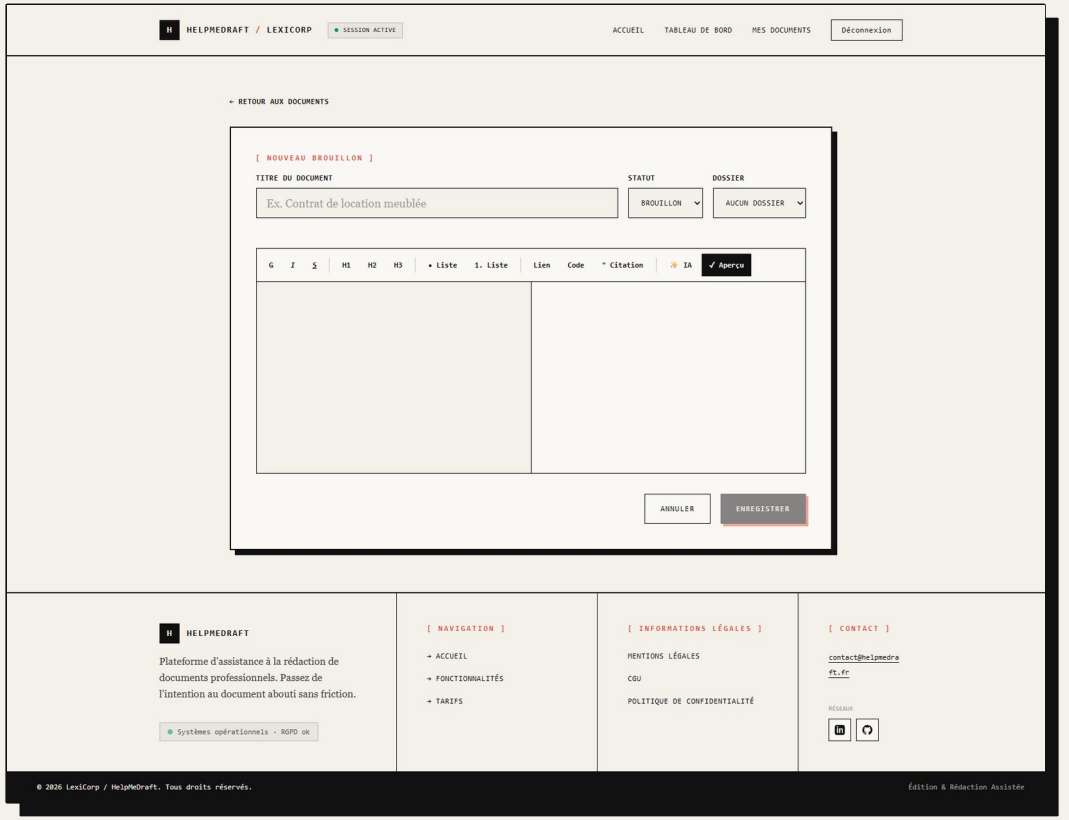
- Trois compteurs — documents créés, brouillons, finalisés — servis par l'API, jamais recalculés côté client.
- Trois portes d'entrée : page blanche, modèle, document existant. Devant un éditeur vide, l'utilisateur sans structure en tête abandonne.
- Pagination serveur : la liste n'est jamais chargée entièrement ; la recherche filtre la page courante.
- État vide explicite plutôt qu'une zone muette.
- Huit captures figurent en annexe § 12.2, avec le code qui les produit.



Capture C-05 — tableau de bord.

Enregistrer 2,5 s après la dernière frappe

- 2,5 s : enregistrer à chaque caractère saturerait l'API ; un délai trop long ferait perdre du travail.
- Le minuteur précédent est annulé à chaque frappe — sinon les requêtes s'empilent.
- Doublé d'un bouton explicite : l'utilisateur garde la main.
- Rien n'est enregistré tant que le titre est vide.
- Une capture atteste d'un état, pas d'un comportement — d'où le jeu d'essai du § 10.



Capture C-07 — éditeur, création d'un document.

Compter les appels, jamais les stocker

Composant métier — le quota IA, contrôlé côté serveur avant tout appel au modèle (dossier § 7.2).

app/routes/ia_route.py

```
window_start = utc_now_naive() - timedelta(hours=24)

calls_last_24h = db_session.execute(
    select(func.count()).select_from(IA).where(
        IA.user_id    == request.user_id,
        IA.created_at >= window_start,
    )
).scalar_one()

if calls_last_24h >= current_user.quota_daily_limit:
    return jsonify({"error": "Quota IA atteint."}), 429
```

Le front affiche le quota restant — mais le contrôle qui compte est celui du serveur.

Une agrégation, pas un compteur

Un compteur stocké se désynchronise ; une agrégation est juste par construction.

Une fenêtre glissante

« 20 par 24 h », pas « par jour » : sinon 40 appels entre 23 h et 1 h.

429, pas 403

« Réessayez plus tard », et non « vous n'avez pas le droit ».

La propriété est dans le WHERE

Composant d'accès aux données — le motif répété pour chaque ressource (dossier § 7.3).

app/routes/document_route.py

```
stmt = select(Document).where(
    Document.id_document == id_document,
    Document.user_id     == request.user_id,
)
document = db_session.execute(stmt).scalar_one_or_none()

if document is None:
    return jsonify({"error": "Document introuvable"}), 404
```

Filtrer, pas vérifier après

Oublier la condition fait échouer un test ; oublier un if ouvre une faille.

404, jamais 403

Un 403 confirmerait que la ressource existe. Le 404 est indiscernable.

ORM paramétré, sans exception

Aucune requête construite par concaténation dans tout le projet.

Les identifiants étant des UUID v4, ils ne sont de toute façon pas énumérables — défense en profondeur.

Conteneurisée, intégrée en continu, pas déployée

Trois services, trois travaux de CI, et une liste de contrôle avant la mise en production (dossier § 6).

3× Conteneurisation

MySQL 8.4, volume persistant et sonde de santé.
Backend sous Gunicorn, utilisateur non privilégié.
Frontend Vite puis Nginx, ~50 Mo.

Secrets en ${VAR:?} : la composition échoue si la variable manque.

CI Intégration continue

GitHub Actions à chaque push et chaque pull request, en trois travaux parallèles : backend (Ruff, pytest), frontend (ESLint, vue-tsc, Vitest, build), Docker (composition et images).

Installation par npm ci --ignore-scripts.

! Avant la mise en production

APP_ENV=production, qui active Secure sur le cookie.
Une JWT_SECRET_KEY distincte.
CORS_ORIGINS au domaine réel.
Compte MySQL sans droits DDL.
TLS devant l'application.
Redis pour le limiteur de débit.

Le piège. SameSite=Strict raisonne en sites, pas en origines. En développement, front et API sont tous deux sur localhost : le cookie passe. En production, il faut deux sous-domaines d'un même domaine, ou l'API derrière un reverse proxy — deux domaines distincts casseraient le rafraîchissement du jeton, et aucun test local ne le verrait.

Ollama reste hors composition, sur l'hôte : son image pèse plusieurs gigaoctets et le modèle se télécharge à part.

5

La sécurité

Dossier § 8 — OWASP Top 10, sessions, contrôle d'accès, validation

La sécurité comme contrainte de conception

Grille OWASP Top 10 (2021), croisée avec le cahier des charges et les recommandations de l'ANSSI.

A01 **Contrôle d'accès**

Propriété dans le WHERE, rôle relu en base à chaque appel /admin, garde de blueprint.

A02 **Cryptographie**

bcrypt salé pour les mots de passe, SHA-256 pour les jetons. Aucun secret en clair en base.

A03 **Injection**

ORM paramétré sans exception ; rendu Markdown assaini par DOMPurify.

A05 **Configuration**

Sans JWT_SECRET_KEY, l'application refuse de démarrer. CORS restreint à l'origine du front.

A07 **Identification**

Rotation des refresh tokens, révocation, limitation de débit, politique de mot de passe.

A10 **SSRF**

Une seule URL sortante : OLLAMA_URL, valeur de configuration, jamais une entrée utilisateur.

A09 — la journalisation applicative reste incomplète : le journal IA existe, pas la journalisation systématique des événements de sécurité.

Un jeton court non révocable, un jeton long révocable

Deux besoins contradictoires, résolus par deux jetons de nature différente (dossier § 8).

Access token

JWT HS256, 15 minutes, en-tête Authorization, jamais stocké en base.

Refresh token

64 octets aléatoires, cookie httpOnly / Secure / SameSite=Strict / path=/auth, 7 jours.

Stockage

Empreinte SHA-256 uniquement : une fuite de la base ne permet pas de rejouer une session.

app/services/auth_service.py

```
if session.revoke:
    revoke_all_user_sessions(
        session.user_id, db_session)
    db_session.commit()
    raise ValueError(
        "Réutilisation détectée")

session.revoke = True
```

Rejouer un jeton déjà consommé est traité comme un vol : toutes les sessions du compte sont révoquées. La gêne est une reconnexion ; le risque évité est un compte compromis.

À la réinitialisation du mot de passe, toutes les sessions sont également supprimées : changer son mot de passe ne sert à rien si les sessions de l'attaquant survivent.

6

Tests, veille et bilan

Dossier § 9 — plan de tests · § 10 — jeu d'essai · § 11 — veille

195 cas au vert, 95 % de couverture backend

Campagne du 3 octobre 2026 — quatre niveaux, du moins coûteux au plus coûteux à exécuter.

195	95 %	59 s	100 %
cas automatisés, tous au vert	couverture backend	durée de la campagne	sur services/ et la persistance

Analyse statique	Tests unitaires	Tests d'intégration	Tests fonctionnels
vue-tsc, Ruff	pytest, Vitest	pytest + client Flask	cahier de tests manuel
`à chaque push`	`à chaque push`	`à chaque push`	`fin d'itération`

! **Les doubles de test mentent**

Trois défauts sont passés sous un faux requests.post trop permissif. Il a fallu un vrai serveur HTTP pour les voir. Les tests ajoutés ensuite ont été vérifiés par mutation — un test qu'on n'a jamais vu échouer ne prouve rien.

La ligne datée de 25 heures

Jeu d'essai sur POST /documents/<id>/ia/generer — la fonctionnalité la plus significative du projet.

? Pourquoi cette route

Elle traverse les trois couches et un système externe, concentre cinq contrôles, et porte les deux exigences les plus délicates : quota et traçabilité.

4 Quatre comptes

U1 utilisatrice principale · U2 tiers, pour l'accès croisé · U3 administrateur · U4 quota abaissé à 1, pour atteindre la limite en un appel.

25 H La donnée décisive

19 lignes de moins de 24 h, et 1 ligne datée de 25 h. Seule façon de distinguer une fenêtre glissante d'un compteur journalier.

Ce que j'en retiens. Construire un jeu de données, ce n'est pas remplir des tables : c'est choisir les valeurs qui font échouer les mauvaises implémentations. Sans la ligne à 25 heures, le cas JE-07 passerait quelle que soit l'implémentation du quota.

Les adresses utilisent le domaine réservé .test et les mots de passe sont des valeurs de test : aucune donnée personnelle réelle dans le jeu d'essai.

La sévérité publiée ne prédit pas l'impact réel

Huit entrées entre avril et septembre 2026, trois ont appelé une action. Journal complet : docs/veille-helpmedraft.html

5.1 **DOMPurify — corrigé**

CVE-2026-0540, contournement du nettoyage XSS. Version affectée : la mienne. Mise à jour en 3.4.16 le 02/10/2026.

Une mesure de sécurité est un composant comme un autre.

9.1 **Ollama — corrigé**

CVE-2026-7482, lecture hors limites sans authentification. Atténuée par l'écoute sur localhost seule. Mise à jour en 0.35.1.

Héberger soi-même, c'est maintenir soi-même.

UE **AI Act — en cours**

Transparence applicable depuis le 02/08/2026. Partiellement couvert ; trois compléments identifiés : mention au premier usage, marquage des passages générés, clause CGU.

axios, 31 mars 2026 — deux versions piégées publiées après la compromission d'un compte mainteneur npm. Projet non affecté. Pas de CVE : ce n'est pas un défaut de code, c'est le canal de distribution qui a été attaqué. C'est le fichier package-lock.json, commité, qui permet de le prouver après coup.

Ce que je retiens

Livré

Cinq lots fonctionnels complets
195 tests automatisés au vert
Docker Compose et pipeline CI
Audits accessibilité et sécurité
Journal de veille et dossier projet

Reste à faire

Déploiement effectif
Bascule complète SQLite → MySQL
Trois compléments AI Act
Journalisation applicative
Tests système et de charge

Appris

Un prompt est du code : il se teste
Une mesure de sécurité est un composant comme un autre
Un jeu de données, c'est choisir les valeurs qui font échouer

Merci de votre attention.